崔屹

人工智能博士候选人 · 多模态推理与智能体系统的可信验证

广州 | (+86) 195-6604-8415 | ycui785@connect.hkust-gz.edu.cn | peter-cui-yi.github.io

男 · 1998.12 · 汉族

教育背景

人工智能（博士） 2024 – 至今
香港科技大学（广州）
导师：Hui Xiong（熊辉）教授——人工智能学域创始负责人（HKUST-GZ）；ACM、IEEE、AAAS、AAAI、CAAI Fellow
副导师：Chengwei Qin 教授
已通过博士资格考试（PQE），2026.08

计算机工程（硕士） （GPA 3.5/4.0） 2024
纽约大学（*New York University*）

计算机科学（本科） （GPA 3.4/4.0；辅修经济学） 2021
宾夕法尼亚州立大学（*Pennsylvania State University*）

研究

我的研究致力于多模态与智能体系统的可信、过程级验证。从揭示 i.i.d. 评测高估真实部署可靠性的基准构建出发（SafeBuild-Bench, KDD'26），进而深入验证层本身：GLANCE 只用原图，预测视觉语言模型在答案相关区域被编辑后会不会随之改答；当前的过程奖励模型工作则追问步骤分数是否跟随决定该步真值的图像事实。我也在研究预训练视频世界模型要付出什么代价才能遵守游戏规则，并把 PQE 综述（从视觉思维链到可验证的视觉思维智能体）扩写为 ACM Computing Surveys 投稿。

论文发表

† 共同第一作者 ∗ 通讯作者

[1] **SafeBuild-Bench: A Temporal-Robust Construction Safety Benchmark with Graph-Enhanced Data Mining.**
Yi Cui†, Zilin Wang†, Yijie Xu, Qianyi Cai, Huizai Yao, Shuai Jiang, Bingzhuo Zhong∗, Hui Xiong∗. **ACM SIGKDD 2026 (KDD)**, Datasets & Benchmarks Track。arXiv:2608.00068

[2] **Beyond Boundaries: Leveraging Vision Foundation Models for Source-Free Object Detection.**
Huizai Yao, Sicheng Zhao, Pengteng Li, **Yi Cui**, Shuo Lu, Weiyu Guo, Yunfan Lu, Yijie Xu, Hui Xiong∗. **AAAI 2026**。arXiv:2511.07301

[3] **From Events to Enhancement: A Survey on Event-Based Imaging Technologies.**
Yunfan Lu, Xiaogang Xu, Pengteng Li, Yusheng Wang, **Yi Cui**, Huizai Yao, Hui Xiong. **arXiv** 预印本，2025。arXiv:2505.05488

在审论文

[4] **Change the Image, Change the Answer? Predicting VLM Responses to Regional Edits.**
Yi Cui, Yili Wang, Zilin Wang, Huizai Yao, Chengwei Qin, Hui Xiong. 在审，**ICLR 2027**。

视觉语言模型答对一道图像问题后，能否仅凭原图上的测量，预测它在答案相关区域被编辑后是跟随编辑改答还是保持原答？*GLANCE* 是一个免训练的三视图分数（全图、放大裁剪、遮蔽区域），全程不看编辑后的图像；在六个 *Visual7W* 模型队列上，它以 *0.71–0.83* 的 *AUROC* 把「跟随编辑」排在「保持原答」之前，并在其中五个队列上超过最强的注意力与几何读数。

在研工作

- **多模态过程奖励模型**（目标 **ACL 2027**）。构建配对图像诊断基准，检验 PRM 的步骤分数是否跟随决定该步真值的图像事实：固定步骤文字，编辑图像使该步真值翻转。工作基于对六个多模态 PRM 的审计，审计发现步骤排序与首错检出并不一致。
- **游戏世界模型**。用程序 harness 让预训练视频模型生成遵守游戏机制的游戏视频，并测量其代价：当事件与模型的视觉先验相悖时，需要多少输入信息、训练数据与核验（推箱子、Griddly、Doom、Hollow Knight）。

- **综述**。将 PQE 综述 *From Visual Chain-of-Thought to Verifiable Visual-Thinking Agents* 扩写为 ACM Computing Surveys 投稿，主题是视觉推理中间表征的验证。

项目

工地安全隐患视觉识别大模型 （广东重工 · 产学合作） 2025 – 至今

Qwen3.6-27B · 全参数 SFT + LoRA（ms-swift）· vLLM FP8 部署 · 华为 Ascend 部署 · 专家参与的数据审计

- 主导工地巡检照片安全隐患识别 VLM 的建模、数据与评测；模型已为产业伙伴部署（单卡 FP8 服务器与对方的华为 Ascend NPU 线上服务）。
- 在 10 万余张巡检图像上微调 Qwen3.6-27B，标签采用专家修订的 231 类隐患体系。在全部 1,156 个独立测试场景上，严格 top-1 准确率由基座的 24.9% 提升到 45.9%，而 Qwen3-VL-235B teacher 只有 27.4%——任务取决于该机构自身的标注习惯，因此放弃了原计划的 teacher 蒸馏。
- 把 top-3 偏低追溯到训练数据（多标签样本仅占 0.15%，模型被训成每图只报一条），在提示词而非训练目标上修复：要求恰好输出 3 个候选后，top-3 准确率由 38.3% 提升到 58.1%，无需重训。
- 按部署效度重建评测：以巡检场景而非单张图片为抽样单元（10,173 张测试图仅对应 1,156 个场景）；用内容哈希剔除与训练集重复的测试照片（约 10%）；两轮专家核对估计图文不符比例为 10–19%，因此所有准确率都注明对应子集。
- 用 vLLM 在线 FP8 量化在单张 NVIDIA L20 上部署，精度无可测损失（top-3 65.8% 对 BF16 的 64.6%，差异在噪声内）；并以内部评测核验对方的 Ascend 部署（750 张验证图上 top-3 60.0% 对 60.1%）。

RedDust ——长程 LLM 智能体评测基准（红沙） （开源：github.com/peter-cui-yi/RedDust） 2026

TypeScript 确定性引擎 · React/Phaser 回放 · LLM-as-judge（人工一致性校验）· 六个 LLM 家族

- 构建 30 天避难所生存基准，不只看 LLM 智能体能否活下来，也看它是否始终可问责：每局 110 个决策，账本追踪智能体在第 0 天许下的承诺，评分为非补偿式多维 profile（结局、诚信、耐久、漂移、理解）。
- 初步跨模型面板显示，短程社交能力相当的智能体在长程一致性上仍会分化：崩掉的智能体并未违背自己的承诺，而是让避难所逐渐衰败；同一个规划脚手架或承诺提醒，能救回一些模型，却会拖垮另一些。

技能

研究方向： 视觉语言大模型 (VLM/MLLM) · 多模态评估与基准构建 · 过程奖励模型 (PRM) / 可验证推理 · LLM 智能体评测 · 数据高效挖掘 / Data-Centric AI

模型训练与部署： 全参数 SFT · LoRA / 参数高效微调 · 知识蒸馏 · 对比学习 · 分布式训练（多 GPU）· FP8 推理部署

编程语言： Python · C++ · Java · TypeScript **框架/工具：** PyTorch · ms-swift · LLaMA-Factory · vLLM · React/Phaser · MATLAB

教学

助教，香港科技大学（广州）

强化学习：原理与方法（AIAA 3053） 应用统计（UFUG 2104）

语言

英语（流利——六年美国留学经历） 中文（母语）