

崔屹

人工智能博士研究生 · 多模态推理与智能体系统的可信验证

广州 | (+86) 195-6604-8415 | ycui785@connect.hkust-gz.edu.cn | peter-cui-yi.github.io

男 · 1998.12 · 汉族

教育背景

人工智能（博士） 香港科技大学（广州） 导师：Hui Xiong（熊辉）教授——人工智能学域创始负责人（HKUST-GZ）；ACM、IEEE、AAAS、AAAI、CAAI Fellow	2024 – 至今
计算机工程（硕士）（GPA 3.5/4.0） 纽约大学（New York University）	2024
计算机科学（本科）（GPA 3.4/4.0；辅修经济学） 宾夕法尼亚州立大学（Pennsylvania State University）	2021

研究

我的研究致力于多模态与智能体系统的可信、过程级验证。从揭示 i.i.d. 评测高估真实部署可靠性的基准构建出发 (SafeBuild-Bench, KDD'26)，进而深入验证层本身——诊断出一种抬高多模态过程奖励评分的隐藏位置先验混淆因素——再到 GLANCE——在不训练、不依赖标注、也不需要编辑图像的前提下，区分「真正用了视觉证据」与「靠先验蒙对」的回答。目前正将问责性评估从感知扩展到长程智能体行为 (RedDust)，并梳理 100+ 篇「视觉思维链 (visual CoT) → 可验证推理智能体」文献，凝练出过程级验证的研究议程（综述撰写中）。

论文发表

† 共同第一作者 * 通讯作者

- [1] **SafeBuild-Bench: A Temporal-Robust Construction Safety Benchmark with Graph-Enhanced Data Mining.**
Yi Cui†, Zilin Wang†, Yijie Xu, Qianyi Cai, Huizai Yao, Shuai Jiang, Bingzhuo Zhong*, Hui Xiong*. **ACM SIGKDD 2026 (KDD)**, Datasets & Benchmarks Track —— 已录用。
- [2] **Beyond Boundaries: Leveraging Vision Foundation Models for Source-Free Object Detection.**
Huizai Yao, Sicheng Zhao, Pengteng Li, Yi Cui, Shuo Lu, Weiyu Guo, Yunfan Lu, Yijie Xu, Hui Xiong*. **AAAI 2026** —— 已录用。
- [3] **Contrastive Graph Matching for Domain Adaptive Object Detection.**
Pengteng Li, Huizai Yao, Yi Cui, Yunfan Lu, Yijie Xu, Minghao Yang, Pinhao Song. **arXiv** —— 预印本。

在投与撰写中

- [4] **Beyond Step AUC: Hidden Position Priors and Capability Trade-offs in Multimodal Process Reward Models.**
Yi Cui, Huizai Yao, Zilin Wang, Zihan Wang, Hui Xiong*. 在审, **ACL 2027**.
已发表的多模态 PRM 排名实际由隐藏的位置先验驱动，而非步骤验证能力：在 *VisualProcessBench* 上，仅用步骤序号的基线达到 0.73 AUC，最好的已训练 PRM 只有 0.36。提出按能力分项的指标与位置受控基线。
- [5] **Grounding or Guessing? A Privileged-Crop Detector of Visual Evidence Use in Multimodal LLMs (GLANCE).**
Yi Cui, Hui Xiong*. 撰写中, 目标 **ICLR 2027**.
不训练、不依赖标注，仅凭未编辑的原图估计多模态大模型是否真的用了视觉证据：对同一答案分别在裁剪、全图、遮蔽三种视图下打分。区分「有据」与「蒙对」达 0.81 AUROC，较最强的区域盲基线高 0.26。
- [6] **RedDust: Short-Horizon Social Skill Does Not Predict Long-Horizon Consistency in LLM Agents.** (红沙)
Yi Cui, Hui Xiong*. 撰写中, 目标 **ICLR 2027**.
独立项目——30 天智能体问责基准。跨模型面板显示，短程社交能力并不能预测长程一致性：早期理解得分相当时，各模型家族在守诺与毁诺之间发生分裂。

项目

Qwen3-VL-32B 学生 (LoRA) · Qwen3-VL-235B-A22B 教师（蒸馏）· 对比式标注 · GEMS · LLaMA-Factory · 8×A6000 · Agentic RAG · vLLM

- 端到端主导数据流水线、模型适配与评测，构建面向重工产业伙伴的行业试点 VLM 系统：自动识别施工现场安全隐患、引用违规法规条文并生成整改建议。
- 经 v2–v5 迭代，在内部验证集上将隐患识别准确率较 baseline 相对提升约 35%——主要来自数据质量优化（对专家标注做语义提取、整理为更精准的隐患分类）与系统提示词优化（加入各类别定义、明确输出格式）。
- 将同家族 Qwen3-VL-235B-A22B 教师经 LoRA 蒸馏至 Qwen3-VL-32B 学生（算力预算下可支撑的最大学生规模），以对比式教师流程自动产出「描述 → 隐患 → 法规 → 整改」结构化标注，大幅降低人工标注成本。
- 从 100K+ 巡检记录中构建经专家复核的 3 万级 SFT 数据集：用 GEMS（图增强数据筛选）治理严重的类别长尾、均衡各隐患类别，让资深工程师聚焦高价值数据而非全量逐条核对；过程中将标签体系由 62 类扩充至 90 类。
- 正在设计将法规引用从「VLM 直接生成」解耦为 Agentic RAG 检索的方案（设计阶段），以提升答案可溯源性与可维护性。

技能

研究方向：视觉语言大模型 (VLM/MLLM) · 多模态评估与基准构建 · 过程奖励模型 (PRM) / 可验证推理 · 数据高效挖掘 / Data-Centric AI

模型训练与方法：LoRA / 参数高效微调 · 知识蒸馏 · 对比学习 · 分布式训练（多 GPU）· Agentic RAG

编程语言：Python · C++ · Java **框架/工具：**PyTorch · MATLAB · React/Phaser · TypeScript · vLLM · LLaMA-Factory

教学

助教，香港科技大学（广州）

强化学习：原理与方法（AIAA 3053） 应用统计（UFUG 2104）

语言

英语（流利——六年美国留学经历） 中文（母语）